

Relatório de Desenvolvimento: Sistema de Predição de Risco de Incêndio (Fire Risk Predictor)

Otávio Ferracioli Coletti, Samuel Rubens Souza Oliveira e Gustavo Lelli Guirao

¹Universidade de São Paulo
São Carlos – SP – Brasil

otaviocoletti@usp.com, samuelrubens@usp.br e gustavo.ल्ली@usp.br
Números USP: 11767796, 11912533, 11918182

1. Introdução, Motivação e Objetivos

A motivação primordial para o desenvolvimento deste projeto é enfrentar a crise crescente de incêndios florestais no Brasil. Em 2024, o país registrou **278.229 focos de calor**, o número mais alto em 14 anos. A Amazônia, bioma mais afetado, teve mais de 140 mil focos, representando um aumento de **77%** em relação a 2023. As consequências são críticas, incluindo perda de biodiversidade, emissão massiva de CO₂, problemas respiratórios e prejuízos econômicos bilionários.

O objetivo principal deste trabalho é **identificar as condições ambientais propícias a incêndios** e utilizar algoritmos de aprendizado de máquina para predição de risco. Foram empregados três algoritmos (Random Forest, MLP e XGBoost) e seus desempenhos foram comparados para determinar a melhor capacidade de generalização.

2. Bases de Dados e Atributos Utilizados

O sistema de predição foi desenvolvido utilizando o **Dataset SISAM** (Sistema de Informações de Saúde Ambiental), que contém aproximadamente **2,6 milhões de registros de focos de calor** desde 2003.

Para treino e validação, foi utilizada uma amostra balanceada de **250.000 registros** (125 mil com ocorrência de incêndio e 125 mil sem). O modelo final foi testado em um conjunto separado de **50.000 registros**.

Os atributos (features) utilizados na modelagem incluíram:

- Coordenadas geográficas: longitude e latitude.
- Parâmetros atmosféricos e de poluição: co_ppb, no2_ppb, o3_ppb, pm25_ugm3, e so2_ugm3.
- Condições climáticas: precipitacao_mmdia, temperatura_c, umidade_relativa_percentual, vento_direcao_grau, e vento_velocidade_ms.
- Variável alvo: incendio (binário, 0 ou 1).

Colunas como data_pas, satellite, bioma, risco_fogo, entre outras, foram descartadas antes da modelagem.

3. Pipeline de Desenvolvimento e Clusterização

O pipeline de desenvolvimento empregou a clusterização inicial dos dados geoclimáticos para criar modelos especializados por região, seguida pela aplicação de modelos de regressão para a predição.

3.1. Etapa de Clusterização

A clusterização foi realizada para agrupar pontos de monitoramento com base em características ambientais similares, o que permite reconhecer perfis de risco distintos entre as regiões. Como vamos analisar dados de pontos de monitoramento do Brasil inteiro 2, vamos identificar a partir de um gráfico de correlação quais condições climáticas mais importam para o desencadeamento ou a não de um incêndio




Figure 1. Biomas do Brasil

No caso, os atributos `temperatura_media`, `co_ppb`, `no2_ppb`, `o3_ppb` e `umidade_relativa_percentual` foram selecionados como os mais importantes para essa detecção. Abaixo alguns passos do pré-processamento e metodologia utilizada na clusterização.

- Preparação de Dados:** Os dados foram agrupados por `latitude` e `longitude`, calculando-se a média dos atributos relevantes em um período de um ano.
- Algoritmo e Parâmetros:** Foi utilizado o algoritmo **K-Means** com o número de grupos fixado em **k=6**.
- Features para Clusterização:** As features usadas foram `temperatura_media`, `co_ppb`, `no2_ppb`, `o3_ppb` e `umidade_relativa_percentual`.

O resultado disso pode ser visto na imagem 4, na qual os clusters gerados são muito semelhantes aos biomas do Brasil.

Distribuição Geográfica




Figure 2. Pontos de monitoramento



Figure 3. Biomas do Brasil

Figure 4. Resultado K-means com k=6

O resultado de cada cluster faz muito sentido quando calcula-se as médias dos atributos utilizados para clusterização e percebemos uma maior quantidade de particulado nas maiores metrópoles do país, São Paulo, Rio de Janeiro e Belo Horizonte e a maior umidade nas no cluster do Litoral e Amazônia. Como se pode ver na imagem 5

	temperatura_media	co_ppb	no2_ppb	o3_ppb	umidade_relativa_percentual	Contagem_Pontos
Cluster_Int						
0	0.250971	0.087946	0.154947	0.541418	0.590004	1600
1	0.695019	0.021688	0.068520	0.694825	0.601079	1160
2	0.859158	0.038141	0.061497	0.646596	0.180117	720
3	0.754719	0.191236	0.097545	0.330874	0.664575	510
4	0.368004	0.213724	0.561710	0.704660	0.592361	152
5	0.550383	0.086900	0.117195	0.540453	0.365249	1430

Figure 5. Média dos atributos de cada cluster

Como resultado da clusterização, fizemos modelos específicos para cada cluster, como forma de atingir melhores resultados que analisando o risco de incêndio de regiões tão heterogêneas.

4. Modelagem e Resultados do Detector de Incêndio

O sistema de predição foi implementado como um problema de **regressão**, onde a saída probabilística foi convertida em uma classificação de risco (detector de incêndio) através da aplicação de um limiar (threshold).

4.1. Modelos Aplicados

Foram avaliados três modelos de aprendizado de máquina para predição:

- **Random Forest Regressor (RF).**
- **Multi-Layer Perceptron (MLP Regressor)**, que necessitou de escalonamento de dados.
- **XGBoost Regressor.**

4.2. Avaliação Global do Desempenho

Na avaliação inicial, o **Random Forest (RF)** demonstrou o desempenho mais expressivo, alcançando um **F1 Score** $\approx 0.85 - 0.90$ na avaliação global. O **MLP** também apresentou boa capacidade de generalização após o escalonamento. A estabilidade dos modelos foi verificada utilizando K-Fold Cross-Validation, com $K = 3$ e $K = 5$.

4.3. Otimização de Limiares por Cluster

Para maximizar o F1 Score em um conjunto de teste separado de 50.000 registros, o limiar de corte (threshold) foi otimizado para cada cluster individualmente, através de uma busca em *grid* de 0.1 a 0.91.

Os resultados nos clusters demonstram a variação na performance regional do modelo Random Forest, exigindo thresholds adaptados:

Table 1. Resultados do Random Forest nos Clusters Geoclimáticos (F1 Score Máximo)

Cluster	Região (Exemplo)	F1 Score Máx	Threshold Ótimo (Aprox.)
0	Pampa e Mata Atlântica Sul	≈ 0.26	≈ 0.7
1	Mata Atlântica/Litoral	≈ 0.375	≈ 0.7
2	Caatinga	≈ 0.43	≈ 0.65

Estes dados mostram que, embora o desempenho global seja alto, o desempenho regional varia significativamente, com o F1 Score máximo atingindo **cerca de 0.43** no cluster associado à Caatinga, reforçando a necessidade da modelagem regionalizada.

5. Plataforma de Disseminação e Melhores Práticas Futuras

O projeto culminou na criação de um sistema, a **Calculadora de risco de incêndio (Fire Risk Predictor)**, com o objetivo de **hospedar todas essas informações e disponibilizá-las para o poder público**, fornecendo uma ferramenta acessível para a gestão de risco e mitigação da crise.

5.1. Recomendações para Melhoria Contínua

Para aumentar a precisão e a robustez do sistema, especialmente nas regiões com menor desempenho, sugerimos as seguintes melhorias:

1. **Melhoria da Performance Regional:** É crucial focar na **otimização de hiper-parâmetros** e na engenharia de features específicas para os clusters com F1 Score abaixo do ideal (e.g., Caatinga).

2. **Enriquecimento da Base de Dados:** Assim como em sistemas de Geração Aumentada por Recuperação (RAG), onde se busca integrar normas adicionais além da ISO 17025, deve-se enriquecer a base de dados do preditor. Isso inclui adicionar outras fontes de dados ambientais ou de uso da terra para criar **embeddings semânticos** mais ricos dos pontos de monitoramento.
3. **Ajuste Dinâmico de Limiares:** O sucesso depende de um *threshold* ótimo. A plataforma deve incorporar a **calibração contínua e dinâmica** desse limiar ou utilizar modelos especializados por cluster para que o poder público possa priorizar, por exemplo, o **Recall** (evitar falsos negativos) conforme a necessidade operacional.